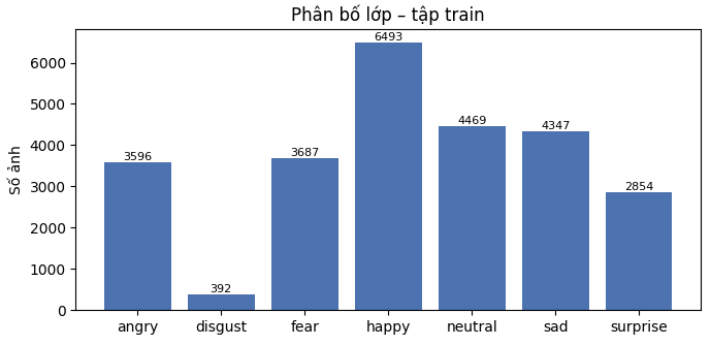
Báo cáo Lab: Nhận diện cảm xúc khuôn mặt bằng Deep Learning

Sinh viên: Trần Thanh Gia Khang – MSSV CE200292 – lớp AI2001 – FPT University Cần Thơ. Bộ dữ liệu FER-2013, framework PyTorch, face detector Haar Cascade.

1. Dữ liệu và tiền xử lý

Dữ liệu là **FER-2013** (Kaggle *msambare/fer2013*): ảnh xám 48×48, 7 lớp cảm xúc, tổng 35.887 ảnh, không dùng dữ liệu ngoài. Thư mục *train/* (28.709 ảnh) được tách 10% theo phân tầng (stratified, seed 42) làm tập **validation**: **train 25.838 / validation 2.871 / test 7.178** ảnh. Tập test chỉ dùng để đánh giá cuối; checkpoint được chọn theo val accuracy.

Lớp	angry	disgust	fear	happy	neutral	sad	surprise
Train (ảnh)	3.596	392	3.687	6.493	4.469	4.347	2.854
Tỉ lệ train	13,9%	1,5%	14,3%	25,1%	17,3%	16,8%	11,0%
Class weight	1,03	9,42	1,00	0,57	0,83	0,85	1,29
Test (ảnh)	958	111	1.024	1.774	1.233	1.247	831



Hình 1. Phân bố lớp trên tập train. Lớp Disgust cực ít (392 ảnh, 1,5%), gấp khoảng 16 lần ít hơn lớp Happy (6.493 ảnh).

Xử lý mất cân bằng. (i) *Class weight* $w_c = N / (K \cdot n_c)$ trong CrossEntropy (Disgust ≈ 9,42; Happy ≈ 0,57); (ii) *augmentation* chỉ trên tập train: lật ngang, xoay ±10°, dịch 10%, co giãn 0,9–1,1, brightness/contrast ±0,3. **Tiền xử lý:** M1 – resize 48×48, chuẩn hoá (x/255 − 0.5)/0.5; M2 – resize 96×96, nhân bản thành 3 kênh, chuẩn hoá theo mean/std ImageNet. Cùng một hàm *preprocess()* (src/predict.py) được dùng cho train, test và ứng dụng realtime nên không bị lệch phân phối đầu vào.

2. Kiến trúc và siêu tham số

M1 – CNN tự thiết kế (3.507.015 tham số, ~343 triệu MACs): 3 block, mỗi block gồm 2×(Conv3×3–BatchNorm–ReLU) → MaxPool2 → Dropout, số kênh 64→128→256, kích thước ảnh 48→24→12→6; sau đó Flatten(9.216) → Linear 256 → BatchNorm1d → ReLU → Dropout 0,5 → Linear 7. BatchNorm giúp ổn định huấn luyện; MaxPool giảm kích thước và tăng tính bất biến dịch chuyển; Dropout (0,25/0,25/0,30/0,50) giảm overfitting vì dữ liệu nhỏ.

M2 – Transfer learning MobileNetV2 (2.232.839 tham số, ~55 triệu MACs ở 96×96): backbone pretrained ImageNet, thay lớp phân loại bằng Dropout(0,3) + Linear(1280→7). Huấn luyện 2 giai đoạn: (1) đóng băng backbone, chỉ train lớp mới 3 epoch (lr 1e-3); (2) mở khoá toàn mạng, fine-tune 20 epoch (lr 3e-4). Chọn MobileNetV2 vì nhẹ, phù hợp yêu cầu ≥10 FPS trên CPU.

Thiết lập chung: AdamW (weight decay 1e-4), CosineAnnealingLR, batch 128, CrossEntropy có class weight, gradient clipping (norm 5), chọn checkpoint theo val accuracy. M1: 40 epoch, lr 5e-4 (lần thử đầu với lr 1e-3 khiến mạng "chết": loss kẹt ở ln 7 ≈ 1,946, acc ≈ 25%, nên giảm lr và thêm BatchNorm1d + gradient clipping). Epoch tốt nhất: M1 epoch 37 (val 64,2%), M2 epoch 21 (val 66,6%).

3. So sánh M1 và M2 (trên tập test, 7.178 ảnh)

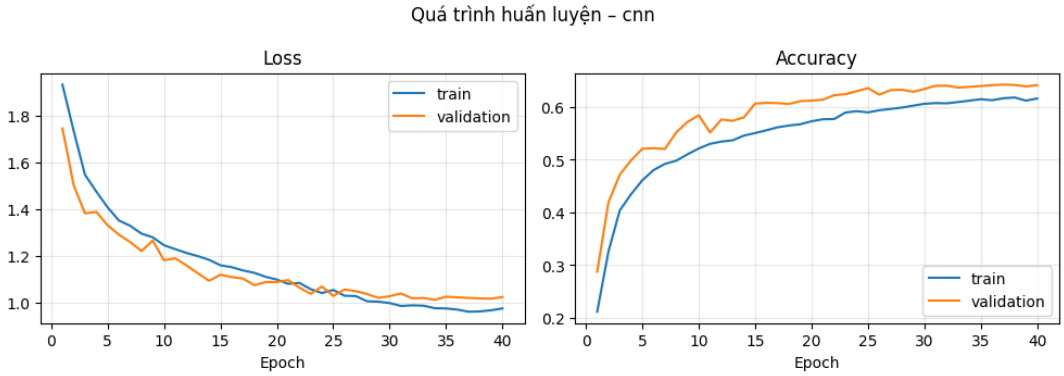
Mô hình	Accuracy	Macro-F1	Tham số	MACs	FPS Colab*	FPS MacBook**
M1 – CNN tự thiết kế	**64,50%** (đạt ≥60%)	0,608	3,51 triệu	343 M	95,9	**28,9**
M2 – MobileNetV2	**66,68%** (đạt ≥65%)	0,652	2,23 triệu	55 M	108,5	**20,2**

** FPS = số khuôn mặt/giây khi suy luận trên CPU của máy Colab, batch = 1, chưa tính detect và hiển thị. ** FPS toàn ứng dụng (đọc luồng + detect + dự đoán + vẽ + hiển thị) đo trên MacBook Pro 13-inch M1, xem mục 6.*

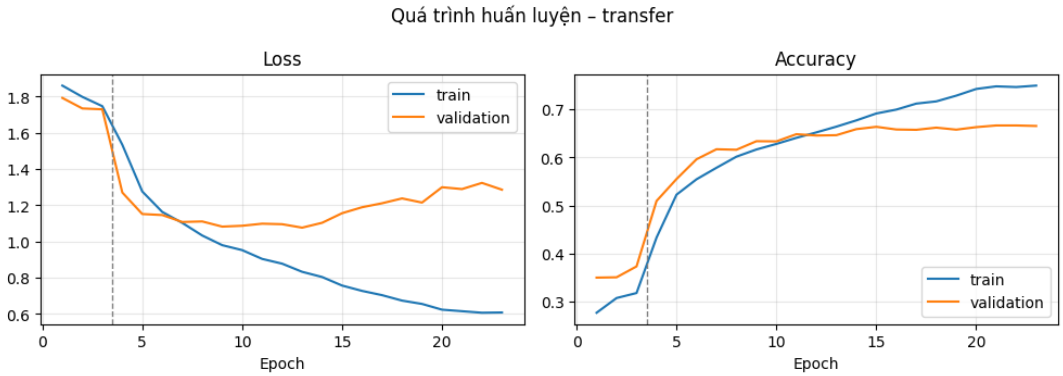
M2 hơn M1 **2,2 điểm %** accuracy và **4,4 điểm** macro-F1, đồng thời ít tham số hơn 36% và ít phép tính hơn ~6 lần. Phần lớn lợi thế đến từ các lớp ít mẫu: F1 của Disgust là 0,682 (M2) so với 0,517 (M1); precision Disgust của M1 chỉ 0,39 (recall 0,77) vì class weight 9,42 khiến M1 dự đoán Disgust quá tay. Hai mô hình cùng yếu ở **Fear** (F1 0,409 / 0,472) và **Sad** (0,512 / 0,534), cùng mạnh ở **Happy** (0,863 / 0,864) và Surprise (0,767 / 0,782). Về tốc độ, kết quả phụ thuộc môi trường đo. Trên CPU Colab (chỉ mô hình, batch = 1) M2 nhanh hơn M1 ~13% dù ảnh vào lớn hơn (96 so với 48), nhờ ít phép tính hơn nhiều (convolution tách kênh). Nhưng trên MacBook M1, cả ứng dụng (mục 6) chạy M1 ở 28,9 FPS và M2 ở 20,2 FPS: số của M1 gần mức ~30 FPS thường gặp của camera nên bị giới hạn bởi nguồn hình hơn là bởi mô hình, còn nguyên nhân M2 chậm hơn trên máy này chưa được kiểm chứng riêng (có thể do PyTorch CPU trên chip Apple xử lý convolution 3×3 thường hiệu quả hơn nhiều lớp depthwise nhỏ). Vì vậy ít MACs hơn chưa chắc cho FPS cao hơn; cả hai đều vượt yêu cầu ≥ 10 FPS.

Ablation class weight (M1). Huấn luyện lại M1 không dùng class weight: accuracy **67,36%**, macro-F1 **0,632**, F1(Disgust) 0,497; có class weight: 64,50%, 0,608, 0,517. Như vậy class weight không cải thiện accuracy/macro-F1 tổng thể trên FER-2013 (giảm ~2,9 điểm accuracy), chỉ nâng recall của lớp hiếm. Chênh lệch F1(Disgust) giữa hai cấu hình rất nhỏ (0,02) và lớp này chỉ có 111 ảnh test nên nằm trong dao động giữa các lần chạy (hai lần chạy cùng cấu hình cho M1 lần lượt 64,04% và 64,50%). Bản nộp vẫn dùng M1 có class weight vì cần nhận được lớp hiếm trong ứng dụng; nếu ưu tiên accuracy tổng thể thì bỏ class weight sẽ tốt hơn.

4. Đồ thị huấn luyện



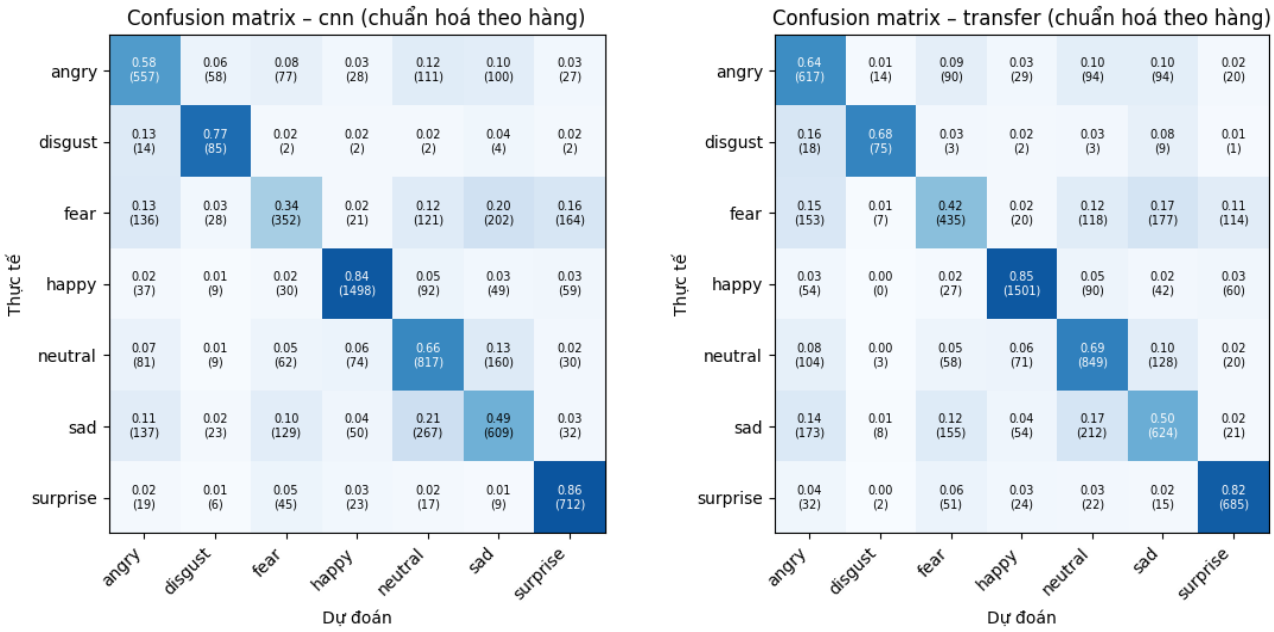
Hình 2. M1: loss/accuracy theo epoch (train và validation).



Hình 3. M2: đường nét đứt là lúc bắt đầu fine-tune toàn mạng (sau epoch 3).

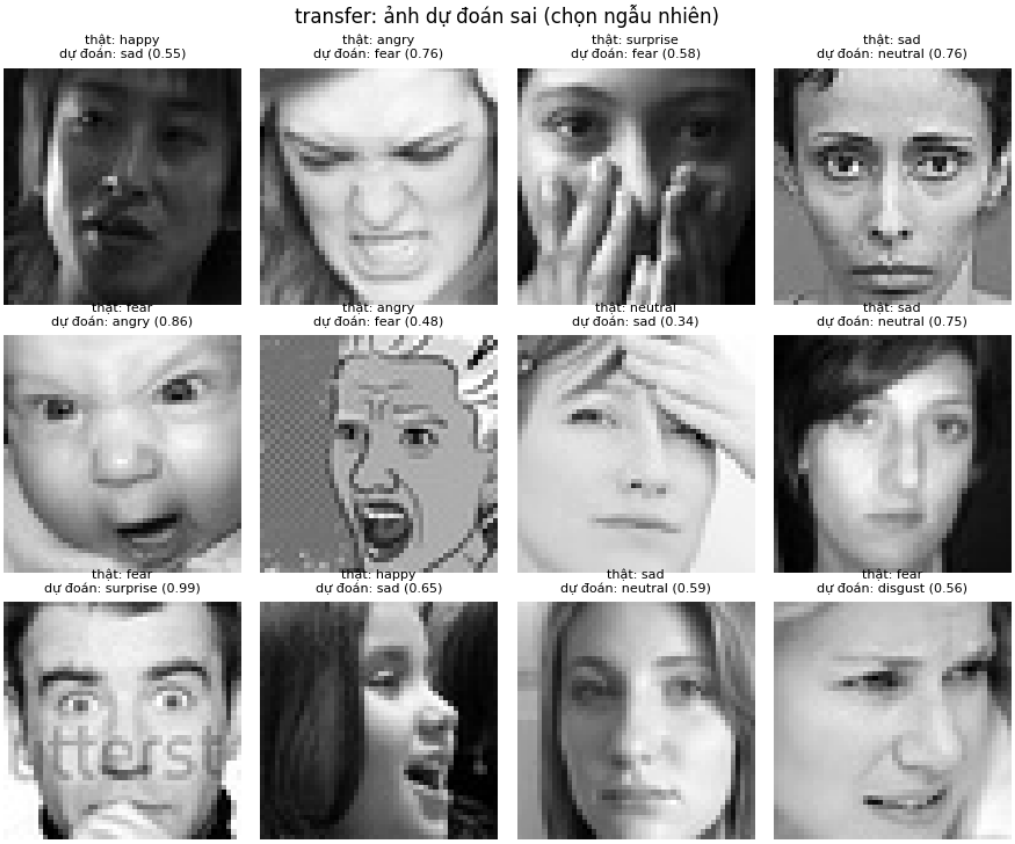
M1 hội tụ chậm và ổn định, không overfit: val accuracy (64,1%) thậm chí cao hơn train accuracy (61,6%) vì train có augmentation và dropout, val loss giảm dần rồi gần như phẳng (~1,01–1,04) từ epoch ~25 (khi lr cosine giảm dần về 0), nên có thể tăng dung lượng mô hình hoặc số epoch để cải thiện thêm. **M2** bị **overfitting** rõ sau epoch ~13: train accuracy tiếp tục tăng lên 74,9% nhưng val accuracy bão hoà ở ~66–66,6% và val loss tăng từ mức thấp nhất 1,076 (epoch 13) lên ~1,29. Việc chọn checkpoint theo val accuracy (epoch 21) tránh dùng bản đã overfit; có thể giảm bằng augmentation mạnh hơn, weight decay lớn hơn, hoặc early stopping quanh epoch 13–21.

5. Confusion matrix và phân tích lỗi



Hình 4. Confusion matrix chuẩn hoá theo hàng (trong ngoặc là số ảnh): M1 (trái), M2 (phải).

Các cặp nhầm lẫn nhiều nhất (số ảnh test). M1: Sad→Neutral 267, Fear→Sad 202, Fear→Surprise 164, Neutral→Sad 160, Sad→Angry 137. M2: Sad→Neutral 212, Fear→Sad 177, Sad→Angry 173, Sad→Fear 155, Fear→Angry 153. Có ba nguyên nhân chính: (1) **biểu hiện gần nhau** – Fear/Surprise cùng có mắt mở to, miệng há hoặc tay che miệng; Sad/Neutral khác nhau chỉ ở độ cong rất nhẹ của miệng và mí mắt; (2) **độ phân giải 48×48** làm mất chi tiết nhỏ (nếp nhăn, khoé miệng) và nhiều ảnh bị mờ/tối/quá sáng; (3) **nhãn FER-2013 nhiễu** – nhãn được gán bởi người, độ đồng thuận thấp, nhiều ảnh rất mơ hồ ngay cả với người; công bố gốc cho thấy độ chính xác của con người trên tập này chỉ khoảng 65 ± 5%, nên mức 64–67% của hai mô hình đã gần trần thực tế. Fear là lớp khó nhất (recall M1 0,34, M2 0,45): bị phân tán sang Sad, Surprise, Angry và Neutral.



Hình 5. 12 ảnh M2 dự đoán sai (chọn ngẫu nhiên, seed 42; nhãn "thật" / nhãn dự đoán và confidence). Đánh số từ trái sang phải, từng hàng từ trên xuống.

#	Thật → Dự đoán (conf.)	Nhận xét nguyên nhân
1	happy → sad (0,55)	Ảnh tối, nhoè, vùng miệng gần như không nhìn rõ nên không thấy nụ cười.
2	angry → fear (0,76)	Nhăn mặt, nhe răng, mắt nheo: biểu hiện cực đoan, gần Fear/Disgust hơn nét Angry điển hình.
3	surprise → fear (0,58)	Tay che miệng, mắt mở lớn – dấu hiệu chung của Surprise và Fear; khó phân biệt nếu thiếu ngữ cảnh.
4	sad → neutral (0,76)	Mắt mở rất to, miệng khép; biểu hiện giống Fear/Neutral hơn Sad – nhiều khả năng nhãn mơ hồ.
5	fear → angry (0,86)	Em bé nhíu mày, trừng mắt, miệng mở: các đường nét giống Angry; nhãn Fear gây tranh cãi.
6	angry → fear (0,48)	Ảnh dạng tranh vẽ/hoạt hình, ngoài miền dữ liệu (ảnh người thật) nên mô hình kém tin cậy.
7	neutral → sad (0,34)	Tay đặt lên trán, ánh nhìn cúi xuống gợi cảm giác buồn dù nhãn là Neutral; confidence thấp.
8	sad → neutral (0,75)	Mặt nghiêng, tóc che một phần, biểu hiện rất nhẹ; thiếu tín hiệu ở vùng miệng–mắt.
9	fear → surprise (0,99)	Mắt mở to, tay che miệng, có chữ (watermark) chèn lên ảnh; Fear↔Surprise nhầm với confidence rất cao.
10	happy → sad (0,65)	Mặt nghiêng/chụp góc xiên, miệng há, tóc che mặt; góc nhìn làm biến dạng đặc trưng nụ cười.
11	sad → neutral (0,59)	Nét mặt gần như trung tính, không có dấu hiệu buồn rõ rệt – nhãn mơ hồ.
12	fear → disgust (0,56)	Nhăn mũi, nheo mắt, nghiêng mặt: các đặc trưng trùng với Disgust.

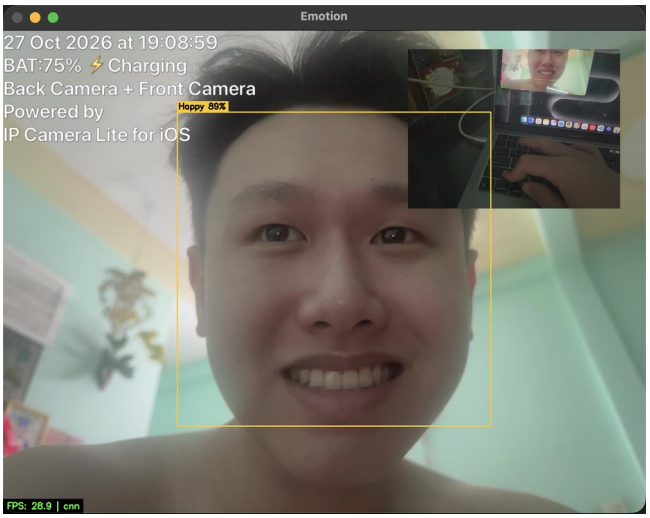
Quan sát chung: nhiều lỗi có confidence thấp (0,3–0,6) nên ngưỡng tin cậy (mặc định 0,5) trong ứng dụng giúp đánh dấu các dự đoán không chắc chắn bằng khung xám và dấu "?". Một số lỗi có confidence rất cao (#9, #5) là do nhãn sai hoặc mơ hồ, không khắc phục được bằng ngưỡng. Với M1 (ảnh lỗi trong notebook), kiểu lỗi tương tự: Angry/Sad bị dự đoán thành Neutral với ảnh biểu hiện nhẹ, mặt nghiêng, đeo kính, ảnh tối hoặc có watermark.

6. Ứng dụng realtime

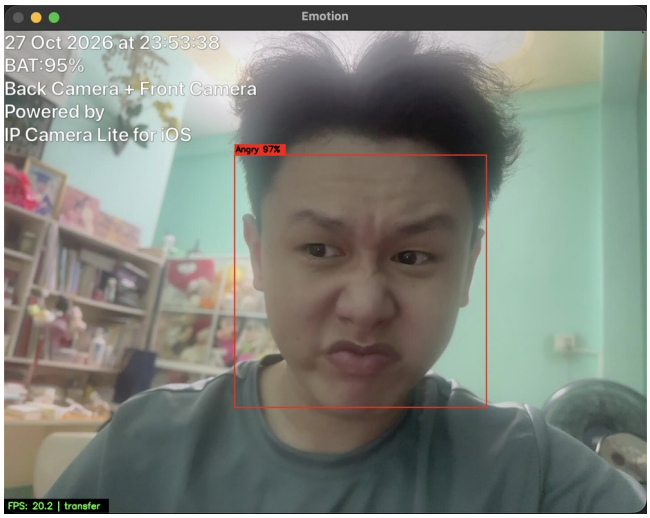
Pipeline: luồng camera (IP Webcam/DroidCam qua URL, webcam, file video hoặc ảnh) → Haar Cascade phát hiện khuôn mặt (ảnh thu nhỏ về chiều rộng 480 px và cân bằng histogram để detect nhanh) → cắt vùng mặt từ ảnh xám gốc → *preprocess()* → M1/M2 dự đoán **cả batch mọi khuôn mặt** trong khung hình một lần → vẽ bounding box, nhãn, confidence và FPS. Lệnh chạy: *python src/app.py --source <url> --model cnn* và *--source test.jpg --model transfer*; địa chỉ camera mặc định đọc từ *config.yaml*, không hard-code.

- **Giảm độ trễ:** thread riêng đọc camera, *CAP_PROP_BUFFERSIZE = 1* và luôn giữ khung hình mới nhất (bỏ khung cũ) nên xử lý chậm không làm hình bị trễ dồn.
- **Mất kết nối:** thread đọc phát hiện lỗi → giải phóng và mở lại kết nối; giao diện hiện thông báo "mất kết nối – đang thử lại", tự chạy tiếp khi có lại; chương trình không crash. Đã thử với luồng MJPEG cục bộ khi tắt/bật lại server.
- **Ngưỡng tin cậy:** confidence < 0,5 → khung xám và nhãn có dấu "?". Ảnh không có mặt in "Không phát hiện khuôn mặt nào"; ảnh/file hỏng báo lỗi rõ ràng.

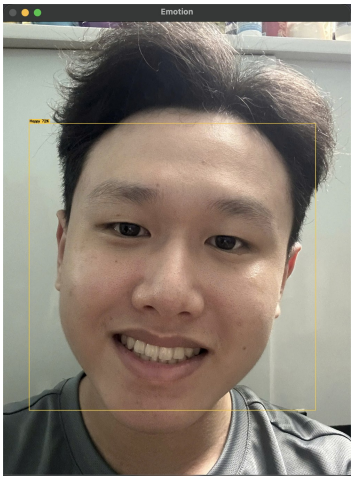
Kết quả demo thực tế. Thiết bị: MacBook Pro 13-inch (chip Apple M1, 2020, RAM 16 GB), chạy bằng CPU; camera là iPhone phát luồng MJPEG qua Wi-Fi bằng ứng dụng IP Camera Lite for iOS. FPS lấy từ bộ đếm hiển thị trên cửa sổ (trung bình mũ, gồm đọc luồng, detect, dự đoán, vẽ và hiển thị): **M1 ≈ 28,9 FPS**, **M2 ≈ 20,2 FPS**, đều đạt yêu cầu ≥ 10 FPS. Mỗi giá trị là một lần đọc trên ảnh chụp màn hình, chưa lặp nhiều lần.



Hình 6. M1, camera iPhone: Happy 89%, 28,9 FPS.



Hình 7. M2, camera iPhone: Angry 97% (nhăn mày, mím môi), 20,2 FPS.



Hình 8. M2 trên ảnh tĩnh (--source ảnh): Happy 72%.

Trên ảnh tĩnh, Haar Cascade tìm đúng khuôn mặt và M2 dự đoán Happy, khớp với nét cười. Khung Haar luôn là hình vuông và thường rộng hơn khuôn mặt (bao cả trán và cằm); phần ảnh thừa này được resize về 96×96 nên có thể làm giảm confidence. Độ tin cậy ở các hình 6–8 không so sánh trực tiếp được vì là các ảnh/khung hình khác nhau.

7. Hạn chế và hướng cải thiện

- **Haar Cascade** chỉ tốt với mặt nhìn thẳng, nhạy với ánh sáng và có thể sinh false positive; thay bằng detector DNN/MediaPipe sẽ chính xác hơn nhưng nặng hơn và thêm phụ thuộc.
- **Khoảng cách miền dữ liệu:** FER-2013 là ảnh xám 48×48 nhiễu nhãn, còn webcam là ảnh màu, độ phân giải cao, ánh sáng khác nên accuracy thực tế có thể thấp hơn số trên test; nên huấn luyện/fine-tune thêm trên FER+ hoặc RAF-DB.
- **Overfitting của M2 và lớp khó (Fear, Sad):** thử augmentation mạnh hơn (CutMix/RandAugment), label smoothing, ensemble M1+M2, hoặc làm mượt dự đoán theo thời gian (trung bình softmax qua vài khung) để ổn định trong video.
- **Kết quả có dao động giữa các lần chạy** (±0,5 điểm % accuracy, lớn hơn với lớp hiếm); các kết luận về chênh lệch rất nhỏ (như ablation trên lớp Disgust) cần lặp nhiều seed để khẳng định.