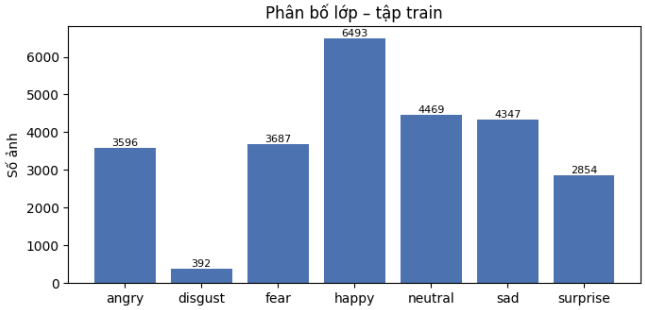
Báo cáo Lab: Nhận diện cảm xúc khuôn mặt bằng Deep Learning

Sinh viên: Trần Thanh Gia Khang – MSSV CE200292 – lớp AI2001 – FPT University Cần Thơ. Dữ liệu: FER-2013 (huấn luyện M1, M2) và RAF-DB (fine-tune M1-R, M2-R, mục 6). Framework PyTorch, face detector Haar Cascade.

1. Dữ liệu và tiền xử lý

Dữ liệu chính là **FER-2013** (Kaggle *msambare/fer2013*): ảnh xám 48×48, 7 lớp cảm xúc, tổng 35.887 ảnh. Hai mô hình cơ sở M1 và M2 chỉ dùng FER-2013. Thư mục *train/* (28.709 ảnh) được tách 10% theo phân tầng (stratified, seed 42) làm tập validation: train 25.838 / validation 2.871 / test 7.178 ảnh. Tập test chỉ dùng để đánh giá cuối; checkpoint được chọn theo val accuracy. Dữ liệu ngoài (RAF-DB) chỉ được dùng ở mục 6.

Lớp	angry	disgust	fear	happy	neutral	sad	surprise
Train (ảnh)	3.596	392	3.687	6.493	4.469	4.347	2.854
Tỉ lệ train	13,9%	1,5%	14,3%	25,1%	17,3%	16,8%	11,0%
Class weight	1,03	9,42	1,00	0,57	0,83	0,85	1,29
Test (ảnh)	958	111	1.024	1.774	1.233	1.247	831



Hình 1. Phân bố lớp trên tập train FER-2013. Lớp Disgust cực ít (392 ảnh, 1,5%), gấp khoảng 16 lần ít hơn lớp Happy (6.493 ảnh).

Xử lý mất cân bằng. (i) Class weight $w_c = N / (K \cdot n_c)$ trong CrossEntropy (Disgust ≈ 9,42; Happy ≈ 0,57); (ii) augmentation chỉ trên tập train: lật ngang, xoay ±10°, dịch 10%, co giãn 0,9–1,1, brightness/contrast ±0,3.

Tiền xử lý. M1 – resize 48×48, chuẩn hoá (x/255 − 0.5)/0.5; M2 – resize 96×96, nhân bản thành 3 kênh, chuẩn hoá theo mean/std ImageNet. Cùng một hàm *preprocess()* (src/predict.py) được dùng cho train, test, fine-tune và ứng dụng realtime nên không bị lệch phân phối đầu vào.

Dữ liệu thêm – RAF-DB. Real-world Affective Faces Database (Li, Deng, Du, CVPR 2017), bản *basic* với ảnh mặt đã căn chỉnh 100×100, 7 lớp, tải từ Kaggle (*shuvoalok/raf-db-dataset*): **12.271 ảnh train** và **3.068 ảnh test** (15.339 ảnh). Nhãn thư mục 1–7 = surprise, fear, disgust, happy, sad, angry, neutral (đã kiểm tra bằng mắt trên lưới ảnh mẫu). Ảnh được chuyển sang xám rồi đi qua đúng *preprocess()*. Số ảnh theo lớp xem Bảng 2 (mục 6). Dataset không đưa vào repo do giấy phép.

2. Kiến trúc và siêu tham số

M1 – CNN tự thiết kế (3.507.015 tham số, ~343 triệu MACs): 3 block, mỗi block gồm 2×(Conv3×3–BatchNorm–ReLU) → MaxPool2 → Dropout, số kênh 64→128→256, kích thước ảnh 48→24→12→6; sau đó Flatten(9.216) → Linear 256 → BatchNorm1d → ReLU → Dropout 0,5 → Linear 7. BatchNorm giúp ổn định huấn luyện; MaxPool giảm kích thước và tăng tính bất biến dịch chuyển; Dropout (0,25/0,25/0,30/0,50) giảm overfitting vì dữ liệu nhỏ.

M2 – Transfer learning MobileNetV2 (2.232.839 tham số, ~55 triệu MACs ở 96×96): backbone pretrained ImageNet, thay lớp phân loại bằng Dropout(0,3) + Linear(1280→7). Huấn luyện 2 giai đoạn: (1) đóng băng backbone, chỉ train lớp mới 3 epoch (lr 1e-3); (2) mở khoá toàn mạng, fine-tune 20 epoch (lr 3e-4). Chọn MobileNetV2 vì nhẹ, phù hợp yêu cầu ≥10 FPS trên CPU.

Thiết lập chung: AdamW (weight decay 1e-4), CosineAnnealingLR, batch 128, CrossEntropy có class weight, gradient clipping (norm 5), chọn checkpoint theo val accuracy. M1: 40 epoch, lr 5e-4 (lần thử đầu với lr 1e-3 khiến mạng "chết": loss kẹt ở ln 7 ≈ 1,946, acc ≈ 25%, nên giảm lr và thêm BatchNorm1d + gradient clipping). Epoch tốt nhất: M1 epoch 37 (val 64,2%), M2 epoch 21 (val 66,6%).

3. So sánh M1 và M2 (trên tập test FER-2013, 7.178 ảnh)

Mô hình	Accuracy	Macro-F1	Tham số	MACs	FPS Colab*	FPS MacBook**
M1 – CNN tự thiết kế	**64,50%** (đạt ≥60%)	0,608	3,51 triệu	343 M	95,9	**28,9**
M2 – MobileNetV2	**66,68%** (đạt ≥65%)	0,652	2,23 triệu	55 M	108,5	**20,2**

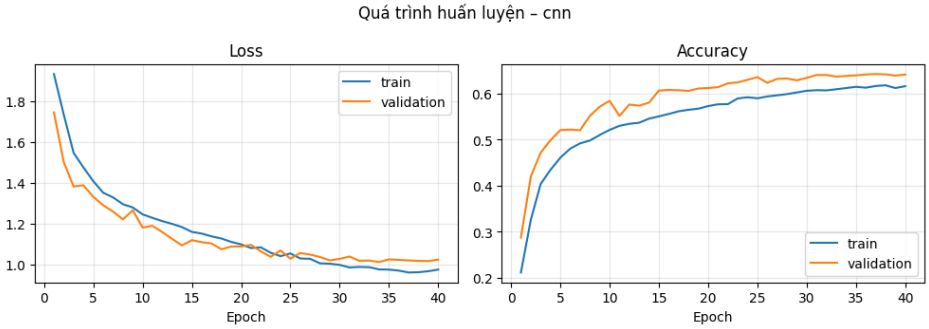
* FPS = số khuôn mặt/giây khi suy luận trên CPU của máy Colab, batch = 1, chưa tính detect và hiển thị. ** FPS toàn ứng dụng (đọc luồng + detect + dự đoán + vẽ + hiển thị) đo trên MacBook Pro 13-inch M1, xem mục 7.

M2 hơn M1 2,2 điểm % accuracy và 4,4 điểm macro-F1, đồng thời ít tham số hơn 36% và ít phép tính hơn ~6 lần. Phần lớn lợi thế đến từ các lớp ít mẫu: F1 của Disgust là 0,682 (M2) so với 0,517 (M1); precision Disgust của M1 chỉ 0,39 (recall 0,77) vì class weight 9,42 khiến M1 dự đoán Disgust quá tay. Hai mô hình cùng yếu ở Fear (F1 0,409 / 0,472) và

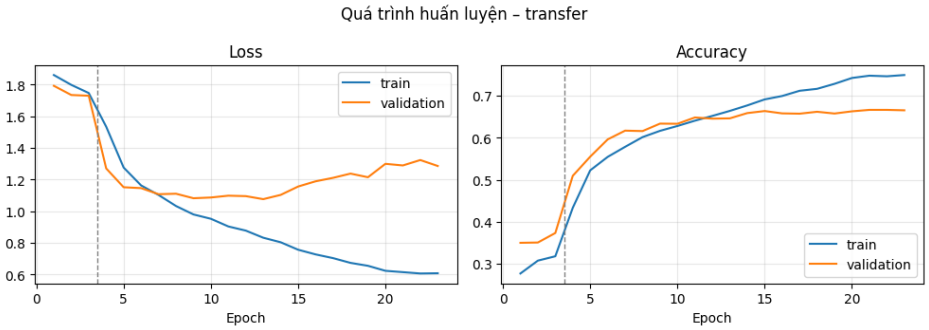
Sad (0,512 / 0,534), cùng mạnh ở Happy (0,863 / 0,864) và Surprise (0,767 / 0,782). Về tốc độ, kết quả phụ thuộc môi trường đo. Trên CPU Colab (chỉ mô hình, batch = 1) M2 nhanh hơn M1 ~13% dù ảnh vào lớn hơn (96 so với 48), nhờ ít phép tính hơn nhiều (convolution tách kênh). Nhưng trên MacBook M1, cả ứng dụng chạy M1 ở 28,9 FPS và M2 ở 20,2 FPS: số của M1 gần mức ~30 FPS thường gặp của camera nên bị giới hạn bởi nguồn hình hơn là bởi mô hình, còn nguyên nhân M2 chậm hơn trên máy này chưa được kiểm chứng riêng (có thể do PyTorch CPU trên chip Apple xử lý convolution 3×3 thường hiệu quả hơn nhiều lớp depthwise nhỏ). Vì vậy ít MACs hơn chưa chắc cho FPS cao hơn; cả hai đều vượt yêu cầu ≥ 10 FPS.

Ablation class weight (M1). Huấn luyện lại M1 không dùng class weight: accuracy 67,36%, macro-F1 0,632, F1(Disgust) 0,497; có class weight: 64,50%, 0,608, 0,517. Như vậy class weight không cải thiện accuracy/macro-F1 tổng thể trên FER-2013 (giảm ~2,9 điểm accuracy), chỉ nâng recall của lớp hiếm. Chênh lệch F1(Disgust) giữa hai cấu hình rất nhỏ (0,02) và lớp này chỉ có 111 ảnh test nên nằm trong dao động giữa các lần chạy (hai lần chạy cùng cấu hình cho M1 lần lượt 64,04% và 64,50%). Bản nộp vẫn dùng M1 có class weight vì cần nhận được lớp hiếm trong ứng dụng; nếu ưu tiên accuracy tổng thể thì bỏ class weight sẽ tốt hơn.

4. Đồ thị huấn luyện



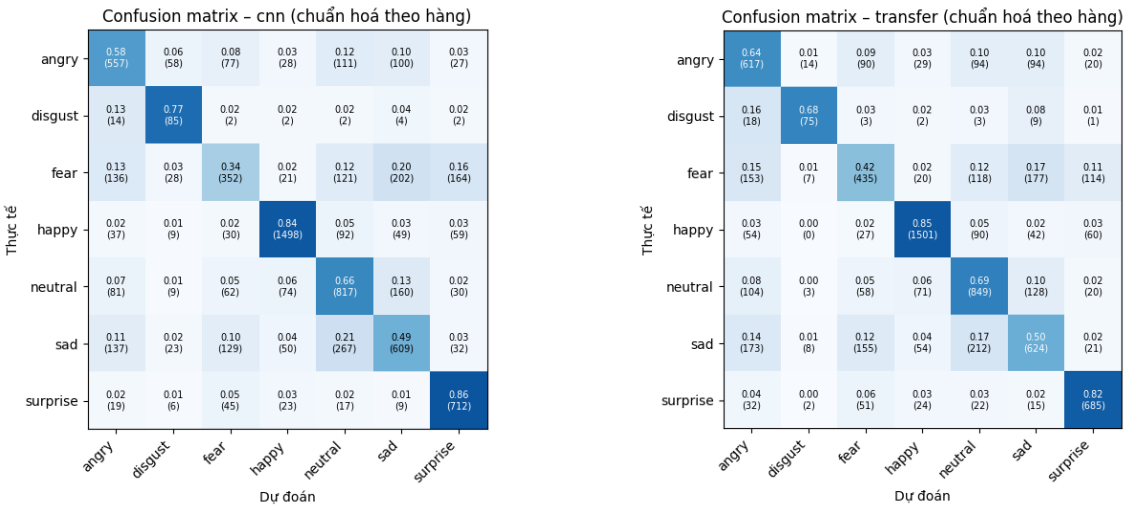
Hình 2. M1: loss/accuracy theo epoch (train và validation).



Hình 3. M2: đường nét đứt là lúc bắt đầu fine-tune toàn mạng (sau epoch 3).

M1 hội tụ chậm và ổn định, không overfit: val accuracy (64,1%) thậm chí cao hơn train accuracy (61,6%) vì train có augmentation và dropout, val loss giảm dần rồi gần như phẳng (~1,01–1,04) từ epoch ~25 (khi lr cosine giảm dần về 0), nên có thể tăng dung lượng mô hình hoặc số epoch để cải thiện thêm. M2 bị overfitting rõ sau epoch ~13: train accuracy tiếp tục tăng lên 74,9% nhưng val accuracy bão hoà ở ~66–66,6% và val loss tăng từ mức thấp nhất 1,076 (epoch 13) lên ~1,29. Việc chọn checkpoint theo val accuracy (epoch 21) tránh dùng bản đã overfit; có thể giảm bằng augmentation mạnh hơn, weight decay lớn hơn, hoặc early stopping quanh epoch 13–21.

5. Confusion matrix và phân tích lỗi



Hình 4. Confusion matrix chuẩn hoá theo hàng (trong ngoặc là số ảnh): M1 (trái), M2 (phải).

Các cặp nhầm lẫn nhiều nhất (số ảnh test). M1: Sad→Neutral 267, Fear→Sad 202, Fear→Surprise 164, Neutral→Sad 160, Sad→Angry 137. M2: Sad→Neutral 212, Fear→Sad 177, Sad→Angry 173, Sad→Fear 155, Fear→Angry 153. Có ba nguyên nhân chính: (1) biểu hiện gần nhau – Fear/Surprise cùng có mắt mở to, miệng há hoặc tay che miệng; Sad/Neutral khác nhau chỉ ở độ cong rất nhẹ của miệng và mí mắt; (2) độ phân giải 48×48 làm mất chi tiết nhỏ (nếp nhăn, khoé miệng) và nhiều ảnh bị mờ/tối/quá sáng; (3) nhãn FER-2013 nhiễu – nhãn được gán bởi người, độ đồng thuận thấp, nhiều ảnh rất mơ hồ ngay cả với người; công bố gốc cho thấy độ chính xác của con người trên tập này chỉ khoảng 65 ± 5%, nên mức 64–67% của hai mô hình đã gần trần thực tế. Fear là lớp khó nhất (recall M1 0,34, M2 0,42): bị phân tán sang Sad, Surprise, Angry và Neutral.



Hình 5. 12 ảnh M2 dự đoán sai (chọn ngẫu nhiên, seed 42; nhãn "thật" / nhãn dự đoán và confidence). Đánh số từ trái sang phải, từng hàng từ trên xuống.

#	Thật → Dự đoán (conf.)	Nhận xét nguyên nhân
1	happy → sad (0,55)	Ảnh tối, nhoè, vùng miệng gần như không nhìn rõ nên không thấy nụ cười.
2	angry → fear (0,76)	Nhăn mặt, nhe răng, mắt nheo: biểu hiện cực đoan, gần Fear/Disgust hơn nét Angry điển hình.
3	surprise → fear (0,58)	Tay che miệng, mắt mở lớn – dấu hiệu chung của Surprise và Fear; khó phân biệt nếu thiếu ngữ cảnh.
4	sad → neutral (0,76)	Mắt mở rất to, miệng khép; biểu hiện giống Fear/Neutral hơn Sad – nhiều khả năng nhãn mơ hồ.
5	fear → angry (0,86)	Em bé nhíu mày, trừng mắt, miệng mở: các đường nét giống Angry; nhãn Fear gây tranh cãi.
6	angry → fear (0,48)	Ảnh dạng tranh vẽ/hoạt hình, ngoài miền dữ liệu (ảnh người thật) nên mô hình kém tin cậy.
7	neutral → sad (0,34)	Tay đặt lên trán, ánh nhìn cúi xuống gợi cảm giác buồn dù nhãn là Neutral; confidence thấp.
8	sad → neutral (0,75)	Mặt nghiêng, tóc che một phần, biểu hiện rất nhẹ; thiếu tín hiệu ở vùng miệng–mắt.
9	fear → surprise (0,99)	Mắt mở to, tay che miệng, có chữ (watermark) chèn lên ảnh; Fear↔Surprise nhầm với confidence rất cao.
10	happy → sad (0,65)	Mặt nghiêng/chụp góc xiên, miệng há, tóc che mặt; góc nhìn làm biến dạng đặc trưng nụ cười.
11	sad → neutral (0,59)	Nét mặt gần như trung tính, không có dấu hiệu buồn rõ rệt – nhãn mơ hồ.
12	fear → disgust (0,56)	Nhăn mũi, nheo mắt, nghiêng mặt: các đặc trưng trùng với Disgust.

Quan sát chung: nhiều lỗi có confidence thấp (0,3–0,6) nên ngưỡng tin cậy (mặc định 0,5) trong ứng dụng giúp đánh dấu các dự đoán không chắc chắn bằng khung xám và dấu "?". Một số lỗi có confidence rất cao (#9, #5) là do nhãn sai hoặc mơ hồ, không khắc phục được bằng ngưỡng. Với M1 (ảnh lỗi trong notebook), kiểu lỗi tương tự: Angry/Sad bị dự đoán thành Neutral với ảnh biểu hiện nhẹ, mặt nghiêng, đeo kính, ảnh tối hoặc có watermark.

6. Mở rộng: fine-tune với RAF-DB (M1-R, M2-R)

Động cơ. Điểm trên FER-2013 chưa phản ánh ảnh từ camera (màu, độ phân giải cao, người khác). Khi đo M1 và M2 (chỉ train FER-2013) trên 3.068 ảnh test của RAF-DB, macro-F1 tụt mạnh: M1 từ 0,608 xuống 0,466; M2 từ 0,652 xuống 0,403 (accuracy 63,1% và 58,8%, được kéo lên chủ yếu nhờ lớp Happy chiếm ~39% test). M2 hơn M1 trên FER

nhưng kém hơn trên RAF-DB, phù hợp với việc M2 bị overfit FER-2013 (mục 4). Ngoài ra thử gộp M1+M2 (trung bình softmax) trên RAF-DB test cho 62,3% / F1 0,443, không vượt M1 nên không dùng.

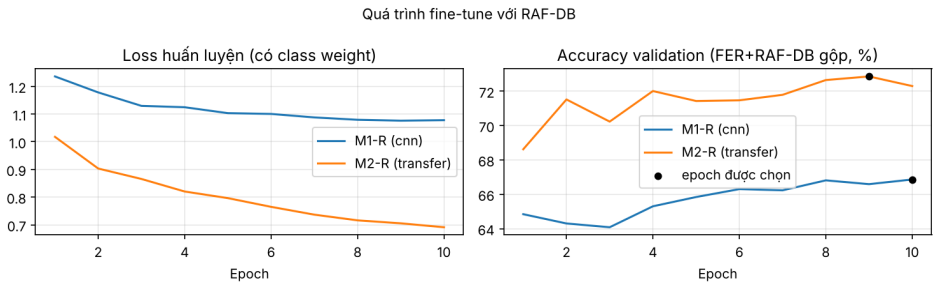
Lớp	angry	disgust	fear	happy	neutral	sad	surprise	Tổng
FER train	3.995	436	4.097	7.215	4.965	4.830	3.171	28.709
RAF-DB train	705	717	281	4.772	2.524	1.982	1.290	12.271
FER test	958	111	1.024	1.774	1.233	1.247	831	7.178
RAF-DB test	162	160	74	1.185	680	478	329	3.068
Class weight (gộp)	1,25	5,08	1,34	0,49	0,78	0,86	1,31	

Bảng 2. Số ảnh theo lớp và nguồn (ảnh FER-2013 ở đây là toàn bộ thư mục train/test gốc; class weight tính lại trên tập train gộp). Nhận xét: RAF-DB có tỉ lệ Disgust cao hơn (717 ảnh) nhưng rất ít Fear (281 ảnh).

Cách làm. Fine-tune toàn mạng từ trọng số M1/M2 đã có trên tập train gộp FER-2013 + RAF-DB (40.980 ảnh), tách 10% phân tầng (seed 42) làm validation: train 36.882 / validation 4.098. Class weight tính lại $w_c = N/(K \cdot n_c)$ trên tập train gộp. Augmentation như mục 1, thêm làm mờ nhẹ (Gaussian) và random erasing để mô phỏng ảnh mặt lớn bị thu nhỏ và bị che. AdamW lr 1e-4, weight decay 1e-4, CosineAnnealingLR, batch 128, 10 epoch, gradient clipping 5; chọn checkpoint theo val accuracy trên tập gộp (M1-R: epoch 10, val 66,9%; M2-R: epoch 9, val 72,9%). Hai tập test (FER-2013 và RAF-DB) chỉ dùng để báo cáo, không dùng để chọn mô hình.

Mô hình	FER-2013 test Accuracy	FER-2013 test Macro-F1	RAF-DB test Accuracy	RAF-DB test Macro-F1
M1 – chỉ FER-2013	64,50%	0,608	63,07%	0,466
M1-R – thêm RAF-DB	62,93% (đạt ≥60%)	0,586	71,71%	0,617
M2 – chỉ FER-2013	66,68%	0,652	58,83%	0,403
M2-R – thêm RAF-DB	**67,23% (đạt ≥65%)**	**0,646**	**76,69%**	**0,683**

Bảng 3. So sánh trước và sau khi thêm RAF-DB. Số tham số và MACs không đổi vì kiến trúc giữ nguyên.



Hình 6. Loss huấn luyện và accuracy validation của M1-R, M2-R theo epoch (chấm đen = epoch được chọn).

- **M2-R:** accuracy RAF-DB +17,9 điểm (macro-F1 +0,279), trong khi FER-2013 giữ được (accuracy +0,55 điểm; macro-F1 −0,006, nằm trong dao động ±0,5 điểm giữa các lần chạy), và vẫn vượt ngưỡng 65% của đề.
- **M1-R:** accuracy RAF-DB +8,6 điểm (macro-F1 +0,151) nhưng FER-2013 giảm 1,57 điểm accuracy (lớn hơn dao động giữa các lần chạy), vẫn đạt ngưỡng 60%. Mô hình nhỏ hơn có ít dung lượng nên đánh đổi giữa hai miền rõ hơn.
- **Lưu ý:** mức tăng trên RAF-DB là kỳ vọng vì train và test cùng phân phối, không tự chứng minh realtime tốt hơn. Bằng chứng gián tiếp là FER-2013 không giảm (với M2-R). Khi thử trực tiếp trên camera iPhone, theo quan sát của sinh viên M2-R cho nhãn đúng và ổn định hơn M2 ở các biểu cảm đã thử (quan sát chủ quan, chưa đo định lượng).

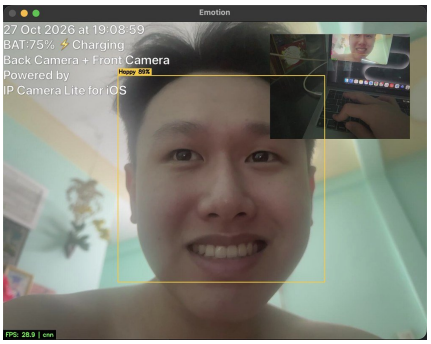
Bản dùng khi demo: M2 = *weights/transfer_raf.pt* (đặt trong config.yaml, dùng cho *--model transfer*); M1 = *weights/cnn.pt*. Các bản còn lại (*transfer.pt*, *cnn_raf.pt*) giữ trong weights/ để so sánh và có thể chọn bằng *--weights*. Mã fine-tune và đánh giá: *tools/finetune_raf.py*, *tools/eval_webcam.py*, notebook *notebooks/finetune_raf.ipynb*.

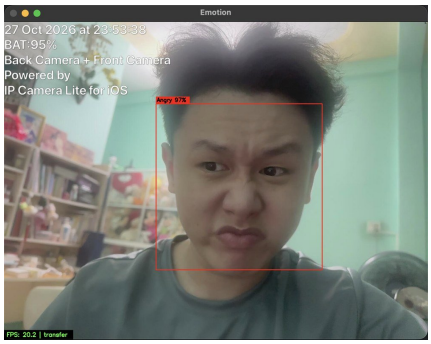
7. Ứng dụng realtime

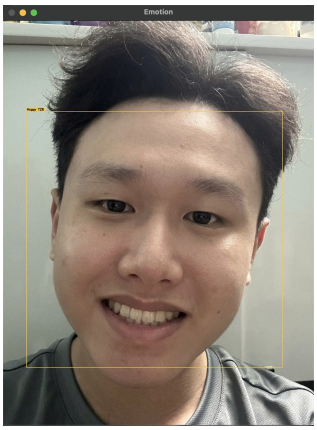
Pipeline: luồng camera (IP Webcam/DroidCam qua URL, webcam, file video hoặc ảnh) → Haar Cascade phát hiện khuôn mặt (ảnh thu nhỏ về chiều rộng 480 px và cân bằng histogram để detect nhanh) → cắt vùng mặt từ ảnh xám gốc → *preprocess()* → M1/M2 dự đoán cả batch mọi khuôn mặt trong khung hình một lần → vẽ bounding box, nhãn, confidence và FPS. Lệnh chạy: *python src/app.py --source <url> --model cnn* và *--source test.jpg --model transfer*; địa chỉ camera mặc định đọc từ config.yaml, không hard-code.

- **Giảm độ trễ:** thread riêng đọc camera, CAP_PROP_BUFFERSIZE = 1 và luôn giữ khung hình mới nhất (bỏ khung cũ) nên xử lý chậm không làm hình bị trễ dồn.
- **Mất kết nối:** thread đọc phát hiện lỗi → giải phóng và mở lại kết nối; giao diện hiện thông báo “mất kết nối – đang thử lại”, tự chạy tiếp khi có lại; chương trình không crash. Đã thử với luồng MJPEG cục bộ khi tắt/bật lại server.
- **Ngưỡng tin cậy:** confidence < 0,5 → khung xám và nhãn có dấu “?”. Ảnh không có mặt in “Không phát hiện khuôn mặt nào”; ảnh/file hỏng báo lỗi rõ ràng.
- **Ổn định dự đoán:** *--smooth N* lấy trung bình softmax của N khung gần nhất cho từng khuôn mặt (ghép theo vị trí) để nhãn bớt nhấp nháy, đổi lại phản ứng chậm hơn ~N khung (chỉ áp dụng cho camera/video, không áp dụng cho ảnh tĩnh); *--crop-scale S* thu nhỏ khung cắt mặt quanh tâm khung Haar vì khung Haar thường bao cả trán và cằm trong khi ảnh huấn luyện là mặt cắt sát. Giá trị mặc định đặt trong config.yaml.

Kết quả demo thực tế. Thiết bị: MacBook Pro 13-inch (chip Apple M1, 2020, RAM 16 GB), chạy bằng CPU; camera là iPhone phát luồng MJPEG qua Wi-Fi bằng ứng dụng IP Camera Lite for iOS. FPS lấy từ bộ đếm hiển thị trên cửa sổ (trung bình mũ, gồm đọc luồng, detect, dự đoán, vẽ và hiển thị): M1 ≈ 28,9 FPS, M2 ≈ 20,2 FPS và M2-R ≈ 24,8 FPS, đều đạt yêu cầu ≥ 10 FPS. Mỗi giá trị là một lần đọc trên ảnh chụp màn hình, chưa lặp nhiều lần. Các ảnh dưới đây chụp với M1 và M2 gốc (chỉ FER-2013); M2-R cùng kiến trúc với M2 nên chi phí suy luận như nhau; chênh lệch 20,2 so với 24,8 FPS là dao động của một lần đọc (nội dung khung hình, số khuôn mặt, tải của máy), không phải do trọng số. M1-R giữ nguyên kiến trúc M1 nhưng FPS toàn ứng dụng chưa được đo riêng.







Hình 7–9 (từ trái sang phải). M1, camera iPhone: Happy 89%, 28,9 FPS. M2, camera iPhone: Angry 97% (nhăn mày, mím môi), 20,2 FPS. M2 trên ảnh tĩnh (--source ảnh): Happy 72%. Độ tin cậy ở các hình không so sánh trực tiếp được vì là các ảnh/khung hình khác nhau. Trên ảnh tĩnh, Haar Cascade tìm đúng khuôn mặt; khung Haar luôn là hình vuông và thường rộng hơn khuôn mặt, nên ứng dụng có tuỳ chọn --crop-scale để cắt chặt hơn.

8. Hạn chế và hướng cải thiện

- Haar Cascade chỉ tốt với mặt nhìn thẳng, nhạy với ánh sáng và có thể sinh false positive; thay bằng detector DNN/MediaPipe sẽ chính xác hơn nhưng nặng hơn và thêm phụ thuộc.
- Khoảng cách miền dữ liệu đã được giảm một phần bằng RAF-DB (mục 6), nhưng chưa có bộ đánh giá định lượng trên video camera thật: test RAF-DB là ảnh căn chỉnh, cùng phân phối với tập train RAF-DB. Hướng tiếp theo là thu một bộ test riêng nhiều người, nhiều điều kiện ánh sáng (đã có *tools/eval_webcam.py* để đo), và thử thêm FER+ hoặc AffectNet.
- Lớp khó (Fear, Sad): RAF-DB chỉ có 281 ảnh Fear train nên khó cải thiện lớp này; chưa phân tích lại confusion matrix sau fine-tune. Thử thêm CutMix/RandAugment, label smoothing, weight decay lớn hơn hoặc early stopping để giảm overfitting của M2.
- Kết quả có dao động giữa các lần chạy (±0,5 điểm % accuracy, lớn hơn với lớp hiếm); các kết luận về chênh lệch rất nhỏ (như ablation trên lớp Disgust, hay macro-F1 FER của M2 và M2-R) cần lặp nhiều seed để khẳng định.